

Định lý Bayes

Công thức nền tảng và ví dụ tính từng bước

1. Công thức trung tâm

$$P(H | D) = \frac{P(D | H) P(H)}{P(D)}$$

H: giả thuyết cần đánh giá; **D**: dữ liệu quan sát.

P(H) - **Tiên nghiệm**: mức tin vào H trước khi thấy dữ liệu.

P(D | H) - **Hàm hợp lý**: khả năng xuất hiện dữ liệu D nếu H đúng.

P(H | D) - **Hậu nghiệm**: mức tin vào H sau khi thấy dữ liệu.

P(D) - **Xác suất của dữ liệu**: dùng để chuẩn hóa; cần $P(D) > 0$.

Cách nhớ: Hậu nghiệm tỉ lệ thuận với Hàm hợp lý $\times$ Tiên nghiệm.

2. Khi có nhiều giả thuyết

Nếu $H_1, \dots, H_k$ loại trừ nhau và bao quát mọi trường hợp, ta cộng đóng góp của tất cả giả thuyết:

$$P(D) = \sum_{j=1}^k P(D | H_j) P(H_j)$$

$$P(H_i | D) = \frac{P(D | H_i) P(H_i)}{\sum_{j=1}^k P(D | H_j) P(H_j)}$$

Trực giác: lấy “điểm” của giả thuyết đang xét chia cho tổng “điểm” của tất cả giả thuyết.

Ví dụ: thư rác có chữ “trúng thưởng”

Gọi S là “thư rác”, T là “có chữ trúng thưởng”. Giả sử:

$P(S) = 0,2$; $P(T | S) = 0,6$; $P(T | \text{không phải } S) = 0,05$.

$$P(S | T) = \frac{0,6 \times 0,2}{0,6 \times 0,2 + 0,05 \times 0,8} = 75\%$$

Xác suất thư rác tăng từ **20%** lên **75%** sau khi thấy bằng chứng.

Học và ước lượng tham số

Từ phân bố hậu nghiệm đến MLE và MAP

3. Công thức học tham số bằng Bayes

Trong học máy, ta cần học tham số θ , chẳng hạn xác suất mặt ngửa của đồng xu. Với θ liên tục:

$$p(\theta | D) = \frac{p(D | \theta) p(\theta)}{\int p(D | u) p(u) du}$$

$p(\theta)$ và $p(\theta | D)$ là **mật độ xác suất**; u là biến lấy tích phân. Tích phân được lấy trên toàn bộ miền giá trị của tham số.

Nếu các quan sát $x_1, \dots, x_n$ độc lập khi biết θ , thì:

$$p(D | \theta) = \prod_{i=1}^n p(x_i | \theta)$$

$$p(\theta | D) \propto p(\theta) \prod_{i=1}^n p(x_i | \theta)$$

Ý nghĩa: kết hợp tiên nghiệm với bằng chứng từ từng quan sát để cập nhật tham số. Ký hiệu $\propto$ nghĩa là “tỉ lệ thuận với”.

4. Chọn một giá trị: MLE và MAP

arg max nghĩa là “giá trị làm biểu thức đạt lớn nhất”.

MLE - Ước lượng hợp lý cực đại

$$\theta_{MLE} = \arg \max_{\theta} p(D | \theta)$$

Chọn tham số giải thích dữ liệu tốt nhất theo hàm hợp lý. **MLE không dùng tiên nghiệm.**

MAP - Ước lượng hậu nghiệm cực đại

$$\theta_{MAP} = \arg \max_{\theta} p(\theta | D) = \arg \max_{\theta} [p(D | \theta) p(\theta)]$$

Chọn tham số có hậu nghiệm lớn nhất, có tính đến tiên nghiệm. Dạng log thường dùng khi tính toán:

$$\theta_{MAP} = \arg \max_{\theta} [\log p(D | \theta) + \log p(\theta)]$$

Dự đoán và phân loại

Bayes đầy đủ và trường hợp Naive Bayes

5. Dự đoán theo Bayes đầy đủ

Thay vì chỉ dùng một giá trị θ , ta kết hợp dự đoán từ mọi giá trị có thể, với trọng số là hậu nghiệm:

$$p(x_{\text{mới}} | D) = \int p(x_{\text{mới}} | \theta) p(\theta | D) d\theta$$

Công thức giả sử dữ liệu mới độc lập với dữ liệu cũ khi đã biết θ .

Hiểu đơn giản: mỗi tham số đưa ra một dự đoán; tham số được tin nhiều hơn đóng góp nhiều hơn. Nếu tham số rời rạc, thay tích phân bằng tổng.

6. Trường hợp cụ thể: Naive Bayes

Với lớp C_k và các đặc trưng $x_1, \dots, x_m$, Naive Bayes giả định các đặc trưng độc lập **khi biết lớp**:

$$p(x_1, \dots, x_m | C_k) = \prod_{j=1}^m p(x_j | C_k)$$

Quy tắc phân loại:

$$\hat{C} = \arg \max_{C_k} [P(C_k) \prod_{j=1}^m p(x_j | C_k)]$$

Tính điểm cho từng lớp rồi chọn lớp có điểm lớn hơn. Mẫu số chuẩn hóa giống nhau giữa các lớp nên không ảnh hưởng đến việc chọn lớp.

Ví dụ: tính điểm cho lớp “thư rác” và “thư thường” từ các đặc trưng của email, sau đó chọn lớp có điểm cao nhất.

Tóm tắt để ghi nhớ

Bayes: cập nhật tiên nghiệm thành hậu nghiệm khi có dữ liệu.

MLE: chọn tham số tối đa hóa hàm hợp lý.

MAP: chọn tham số tối đa hóa hậu nghiệm.

Bayes đầy đủ: kết hợp các giá trị tham số khi dự đoán.

Naive Bayes: phân loại bằng giả định độc lập có điều kiện.

Thứ tự học: nắm chắc định lý Bayes và ví dụ ở trang 1, sau đó mở rộng sang học tham số và dự đoán.